

刘辉 27 届 男 24 应聘岗位：大模型算法工程师 微信：19114942172 邮箱:liuhui_jxfe@163.com

教育背景

硕士：复旦大学	数学交叉学科研究院	人工智能专业	2025.09~2027.07
本科：江西财经大学	金融学院	金融工程专业	2019.09~2023.07

实习经历

阿里巴巴集团股份有限公司	岗位：大模型算法工程师	2025.12~2026.04
--------------	-------------	-----------------

项目背景：

ai 搜索技术相比传统搜索具有灵活性和复杂意图理解上的巨大优势，项目目标是提升搜索全链路的效能，响应时间、搜索精准度、复杂意图理解、相关性过滤等能力。

模型训练层面：

1.针对 query 解析模型 Qwen3-4B、8B base model 进行 SFT 和 GRPO 强化学习训练，利用严格的多类型多样 PE 合成清洗标注了 2500 条训练数据，收集线上数据 125 条进行标注作为测试集，进行大量的对比和消融实验，最终 4B-SFT 微调 acc 指标是 0.872，相对 base 提升 23.7%；在 SFT 最好的 ck 进行多版本 GRPO，sota 版本 4B-rl 模型 acc 指标 0.904，提升了 3%；8B-SFTacc 指标最高为 0.912，8B-SFT+GRPO 指标 acc 为 0.856 有一定的退化，归因是**高容量模型在有限且有偏的 reward 信号下，过度优化了与最终 acc 指标不完全对齐的目标，同时 GRPO 超参未适配 8B 模型。**

解决方案：

调参层面：加大 kl 惩罚系数做消融；设置不同的探索系数做消融；降低学习率等
奖励层面：根据长度二分类多目标加权奖励 数据层面：增加了采样过滤机制，减少低质量轨迹
结果：8B-SFT-RL 模型 acc 提升至 0.93，相比 8B-SFT 提升 1.8%，已经上线投入运行；
通过 pass@K 实验，对模型 32 次推理详细轨迹分析，发现 RL 训练的最大潜力在于提高高 reward 路径的采样概率。SFT 模型虽已学习到有效知识，但推理路径不稳定，通过强化学习把原本偶发高分行为变成稳定输出，同时激发共享了当前推理模式的其他 max@k≈0 难例的提升。
数据迭代和扩充：对训练集 badcase 进行逐个 pass@32 精细分析，发现主要问题在于起始标注数据错误、分类界限模糊导致，模型容易在结构化标签与模糊情节查询出现失误，优化补充相应训练数据

搜索链路层面：

query 解析优化：串行转单个，且多 query 下并行：原逻辑对简单 Query 友好但对复杂 Query 存在多次重试和串行解析。现在修改为统一相关性解析，虽然极少数极简 Query 略微变慢，但大幅收敛了复杂 Query 的长尾耗时，整体方差变小，用户感知更稳定，解析时间从 2.81s 降至 1.89s，大幅提升效率。RT 收益：线上 35%流量的单节目信息查询 query 的内容响应时间由原来的 10s 降到 3s。

撞表逻辑引入：判断 query 是否是特定节目/剧集，直接和本地节目单匹配，不走后续链路，直接返回结果。

OneREC 生成式推荐项目

背景：利用编码器解码器结构替代传统的召粗精推荐模型架构，缓解新品冷启动难题。
工作：先利用 RQVAE 将文本进行 SID 编码，模型完整读取用户历史物品列表，预测下一个物品 sid，利用束搜索保留 top-k 个束形成推荐列表返回
数据集：amazon 工业用品、办公用品数据集 8w 条 训练思路：SFT+GRPO 两阶段训练流程

项目优化亮点：

- 1.RL 阶段的约束解码和束搜索：
问题：动作空间是物品 SID 的闭集，重采样容易产生重复项，造成计算资源浪费。将动态采样和束搜索相结合，保证输出有效同时扩大覆盖范围。动态采样给模型加温度系数 temperature 让概率分布变得更平滑束搜索采用束宽 16，一次保留 top-K 条最优生成路径，最后选整条序列对数概率和最高的。
- 2.奖励优化：原始 GRPO 二元奖励解决不了排序质量问题，引入排序型奖励，对得分更低难度更高的负样本进行惩罚。这个设计的目的在于逼模型学会真正区分正负样本，防止随便乱猜。给模型的错误候选打分：越自信（排名越靠前）的错误，惩罚越重；最后归一化，方便叠加到总奖励里。

训练结果：和传统推荐模型 SASrec, Caser, GRU4rec, 其他生成式模型 HSTU, Lc4rec 对比在 HR@3 数据集从 0.06 提升到 0.11, HR@10 从 0.09 提升到 0.15, NDCG@5 从 0.05 提升到 0.10, 相比其他生成式提升 1-2 个点。

尝试用传统推荐模型（如 SASRec）的打分当奖励。结果：效果变差。

原因：奖励作弊，模型为了拿高分，故意输出传统模型喜欢的东西，拟合错误的分布，但和真实推荐目标不匹配，越训越偏。

推荐业务实践中可以继续尝试奖励扩展：正向奖励：点击奖励、加购奖励、成交转化奖励

负向惩罚：重复推荐惩罚、低质商品惩罚、违规内容惩罚

北京智谱华章科技股份有限公司

大模型 agent 算法工程师

2025.3~2025.08

项目背景：现有的 agent 智能体执行能力还有很大提升空间，用户需要端到端的结果，具体实践过程中往往产生多轮对话的任务理解不足、指代消解、前后逻辑矛盾、注意力稀释、工具调用错误、上下文 token 长度限制等问题，这是 agent 落地过程中急需解决的问题。

产出：在基座模型 GLM4-32B 基础上针对企业级任务理解 agent 继续进行后训练、高质量数据合成策略、自主解决模型评测和对比设计指标体系、利用 SFT—DPO—GRPO 三阶段训练流程，提升 agent 能力，以解决实践中的痛点。

具体内容：

1. SFT 数据集：MiroVerse-v0.11w 条数据+5w 条自主合成数据 SFT：利用 ms-swift 框架进行 LORA 微调，rank 选取 8 之后合并模型权重
- 2.评测：自主设计了评测脚本，利用 VLLM 进行推理并评测在验证集上的表现，张量并行策略使得评测和推理评测速度提升 10 倍，模型学会了模仿数据集的语言风格，回复结构，各指标提升 0.02-0.05
- 3.设计数据合成管道方案：自主设计脚本，批量进行合成，人工审核数据效果：分具体语料来源、任务需求，合成不同的格式。主要采用的数据合成管道策略：构建文档语料库-生成多跳问题对-转换成智能体轨迹。预处理：去除原始文档中的冗余信息，字典中加上 tokens_count 方便后续整理数据进行采样。智能体轨迹结构：思考-调用工具-观察结果-再思考-最终回答。轨迹合成与质量筛选 Pipeline：将合成的 query 发送至接入模型的 agent 端；每条 Query 并行调用不同模型生成多样化的候选轨迹；过滤未完成任务的 bad 轨迹与步骤不完整的 partial 轨迹，选取最优轨迹作为 SFT 数据，累计构建 5 万余条高质量训练数据。
- 4.具有自主排查能力：实验中出现的问题：进行之后模型推理过程突然消失的问题。然后我就把多轮对话中输入模型的提示词，打印出来进行校验，排查问题，发现是二次分词器的原因导致的问题，模型输出推理过程最终恢复正常。
5. 偏好数据构造方案：针对同一 query 设计 H+/H-：H+ 为步骤合理、工具调用精简、格式规范的优质轨迹；H- 通过对 H+ 进行扰动生成，包括删除验证步骤、注入错误工具参数、引入冗余操作等方式，构造覆盖多种失败模式的负样本。
- 6.RL 训练强化学习方案设计：设计 LLM-as-Judge 评分体系，从工具调用合理性、推理链完整性、格式规范性三个维度对候选轨迹打分。利用 DPO 和 GRPO 训练方法，评测模型能力，进行迭代优化。由 LLM 加权融合打分，选取有前一轮 RL 过程中高质量的轨迹，作为下阶段训练的数据，逐步扩展模型多轮对话长上下文理解能力和任务完成工具调用能力。